

Traitement Informatique des Données

TP2 – Tables dynamiques avec LibreOffice Calc

Objectifs

Dans le TP précédent, nous avons manipulé directement les lignes d'un jeu de données à l'aide de formules.

Nous allons maintenant nous intéresser à une autre question :

comment résumer plusieurs centaines ou milliers de lignes rapidement ?

Pour cela, nous allons utiliser les **tables dynamiques** de LibreOffice Calc.

Nous travaillerons pendant tout le TP avec un jeu de données contenant des tweets publiés autour du Nouvel An 2015 et décrivant les bonnes résolutions de leurs auteurs.

À l'issue du TP, vous devrez notamment savoir :

- créer une table dynamique ;
- compter des observations par catégorie ;
- croiser plusieurs variables ;
- afficher des résultats sous forme de pourcentages ;
- filtrer et trier les résultats ;
- étudier une distribution temporelle ;
- représenter graphiquement une table dynamique.

Commencez par télécharger le fichier `new_years_resolutions.csv` disponible sur la plateforme pédagogique, puis ouvrez-le avec LibreOffice Calc.

1 Découvrir le jeu de données

Chaque ligne du tableau correspond à un tweet.

Parmi les informations disponibles, on trouve notamment :

- la date et l'heure du tweet ;
- le texte original ;
- la catégorie de la résolution ;
- un thème plus précis associé à la résolution ;
- la localisation de l'utilisateur ;
- son État américain ;
- sa région ;
- son fuseau horaire ;
- son genre.

Prenez quelques minutes pour parcourir le tableau.

Observez en particulier les colonnes :

`tweet_category`, `tweet_topics`, `tweet_state`, `tweet_region`

ainsi que la colonne contenant la date et l'heure du tweet.

Nous allons essayer de comprendre ce que ces données racontent sur les bonnes résolutions prises pour l'année 2015.

2 Première table dynamique

Nous souhaitons tout d'abord savoir quelles catégories de résolutions sont les plus fréquentes.

Sélectionnez le tableau puis créez une nouvelle table dynamique à partir des données.

Dans cette table :

- placez `tweet_category` dans les lignes ;
- utilisez également `tweet_category` comme champ de données ;
- choisissez un calcul permettant de **compter** le nombre de tweets.

Vous devez obtenir une table donnant le nombre de tweets pour chaque catégorie de résolution.

Triez les résultats de la catégorie la plus fréquente à la moins fréquente.

Observez le résultat.

Quelles catégories semblent particulièrement importantes dans les résolutions du Nouvel An ?

3 Passer des effectifs aux proportions

Les nombres bruts permettent de comparer les catégories, mais il est souvent plus facile d'interpréter une distribution sous forme de pourcentages.

Modifiez votre table dynamique afin d'afficher la part de chaque catégorie dans l'ensemble des tweets.

Le total doit représenter :

100 %.

Comparez les résultats obtenus avec les effectifs de la section précédente.

Remarque : une même information peut donc être présentée sous plusieurs formes sans modifier les données d'origine.

4 Croiser plusieurs variables

Une table dynamique devient particulièrement intéressante lorsque l'on souhaite étudier plusieurs variables simultanément.

Modifiez votre table afin de comparer les catégories de résolution selon la région géographique.

Utilisez :

- `tweet_category` en lignes ;
- `tweet_region` en colonnes ;
- le nombre de tweets comme valeur.

Vous obtenez maintenant un tableau à deux dimensions.

Observez les différentes régions :

- certaines catégories semblent-elles plus présentes dans une région que dans une autre ?
- les différences observées sont-elles faciles à interpréter à partir des effectifs seuls ?

Essayez ensuite d'inverser les lignes et les colonnes.

La table contient exactement la même information, mais la lecture du résultat est différente.

5 Ajouter un filtre

Nous souhaitons maintenant pouvoir explorer seulement une partie du jeu de données.

Ajoutez `user_gender` comme filtre de la table dynamique.

Affichez successivement :

- l'ensemble des tweets ;
- uniquement les tweets associés aux utilisateurs `female` ;
- uniquement les tweets associés aux utilisateurs `male`.

Observez comment la table se met à jour lorsque le filtre change.

Vous pouvez également essayer d'utiliser `tweet_region` comme filtre.

6 À quelle heure tweetait-on ses bonnes résolutions ?

Le champ `tweet_created` contient à la fois la date et l'heure de publication.

Nous souhaitons étudier uniquement l'heure de la journée.

Dans le tableau original, ajoutez une nouvelle colonne appelée :

Heure

Dans la première ligne de données, extrayez l'heure à partir de la date de création du tweet.

Selon la configuration de LibreOffice Calc, la fonction permettant d'extraire l'heure peut apparaître sous la forme :

```
=HOUR(A2)
```

ou sous son équivalent français.

Recopiez ensuite la formule sur l'ensemble du jeu de données.

Créez une nouvelle table dynamique dans laquelle :

- l'heure apparaît dans les lignes ;
- le nombre de tweets apparaît comme valeur.

Vous obtenez ainsi la distribution du nombre de tweets au cours de la journée.

Triez naturellement les heures de 0 à 23.

7 Représenter les résultats

Une table est utile pour connaître les valeurs exactes, mais une représentation graphique permet souvent d'identifier plus facilement une tendance.

À partir de la table précédente, créez un diagramme représentant le nombre de tweets en fonction de l'heure.

Choisissez une représentation adaptée à une variable discrète comme l'heure de la journée.

Votre graphique doit permettre d'identifier facilement :

- les périodes pendant lesquelles peu de tweets sont publiés ;
- les périodes les plus actives ;
- l'heure correspondant au maximum de tweets.

Donnez un titre explicite au graphique.

8 D'où viennent les tweets ?

Nous allons maintenant nous intéresser à la dimension géographique.

Créez une nouvelle table dynamique donnant le nombre de tweets pour chaque valeur de :

`tweet_state`

Triez les États du plus grand au plus petit nombre de tweets.

Certains États apparaissent-ils très nettement devant les autres ?

Créez ensuite un diagramme permettant de comparer les États les plus représentés.

Il n'est pas nécessaire d'afficher tous les États si cela rend le graphique illisible : vous pouvez vous limiter aux valeurs les plus importantes.

9 Explorer les thèmes plus précisément

La colonne `tweet_category` fournit une catégorie générale.

La colonne `tweet_topics` contient une description plus précise de la résolution.

Créez une table dynamique permettant d'étudier les thèmes présents dans une catégorie particulière.

Vous pouvez par exemple :

- mettre `tweet_category` comme filtre ;
- mettre `tweet_topics` dans les lignes ;
- compter le nombre de tweets.

Choisissez une catégorie qui vous semble intéressante puis observez les sous-thèmes qu'elle contient.

Cette étape montre l'intérêt d'une table dynamique pour passer rapidement d'une vue générale à une vue plus détaillée.

Pour aller plus loin

Si vous avez terminé le TP, utilisez les variables du jeu de données pour répondre à une question de votre choix.

Quelques exemples :

- les catégories de résolutions sont-elles les mêmes selon les régions ?
- certaines catégories sont-elles davantage représentées chez les hommes ou chez les femmes ?
- les thèmes abordés changent-ils selon l'heure de publication ?
- quelle région produit proportionnellement le plus de tweets liés à la santé et au fitness ?

Construisez la table dynamique qui vous semble la plus adaptée à votre question.

Si le résultat s'y prête, représentez-le également à l'aide d'un graphique.

Bilan

Durant ce TP, vous avez utilisé les tables dynamiques pour résumer et explorer un jeu de données.

Vous avez notamment appris à :

- compter automatiquement des observations par catégorie ;
- afficher des résultats sous forme de proportions ;
- croiser plusieurs variables ;
- filtrer une table dynamique ;
- modifier son organisation sans modifier les données ;
- étudier une distribution selon l'heure ;
- trier les résultats ;
- créer une représentation graphique à partir d'une synthèse.